

Atari Pong


DQN, Double DQN e Reward Shaping

Un confronto multi-seed su come target TD, esplorazione e reward ausiliari cambiano il training.

Track 34: Learn to Play Atari Pong with Deep Reinforcement Learning


Alessandro Maria Gullotti

<https://github.com/alessandrogullotti02/dl26-projects>



policy da pixel → azione

Il problema: imparare una policy con reward sparso



REWARD ATARI ORIGINALE

```
r_t = +1  se punto vinto  
r_t = -1  se punto perso  
r_t = 0   altrimenti
```

la maggior parte degli step ha reward 0

1.8M

step per run

20



episodi
greedy/checkpoint

3

seed primari

Protocollo: confronto controllato

Rendere confrontabili le famiglie sperimentali: stessi seed, stesso budget, stessa evaluation.



FAIRNESS DEL CONFRONTO

- Seed allineati
- Budget identico
- Evaluation identica

Le schedule esplorative confrontate hanno estremi controllati

Metodo: una DQN convoluzionale da pixel a Q-value

La baseline implementa il ciclo DQN classico: replay buffer + target network + Huber loss.



$$y = r + \gamma_{\text{disc}}(1 - d) \max_{a'} Q_{\text{target}}(s', a')$$
$$\delta = y - Q_{\text{online}}(s, a)$$
$$L = \text{SmoothL1}(\delta)$$

target DQN + Huber loss

Scelte progettuali

- target network separata: riduce instabilità del bootstrap
- replay buffer: rompe correlazioni temporali dei frame
- Huber/SmoothL1: meno sensibile a TD error molto grandi

Che cosa cambia rispetto alla baseline?

Tre famiglie sperimentali, tutte valutate con lo stesso protocollo greedy sul reward Atari originale.

Target TD

Double DQN

separa selezione e valutazione

$$a^* = \arg \max Q_{\text{online}}(s', a')$$

$$y = r + \gamma_{\text{disc}} Q_{\text{target}}(s', a^*)$$

Esplorazione

ϵ -greedy

lineare · esponenziale · costante

$$\epsilon_{\text{lin}}: 1 \rightarrow 0.01$$

$$\epsilon_{\text{exp}}: \text{decresce prima}$$

$$\epsilon_{\text{const}}: 0.10 \text{ dopo warm-up}$$

Reward shaping

training reward

rally · PBRS · contatto

$$\tilde{r} = r_{\text{Atari}} + b_t$$

$$\text{PBRS: } b_t = \gamma_{\text{disc}} \Phi(s') - \Phi(s)$$

confronto sperimentale controllato + diagnostiche qualitative; metodi e teoria sono presi dalla letteratura.

Double DQN migliora il return medio, ma il dato resta descrittivo

Sul confronto paired finale, Double DQN supera Vanilla DQN su tutti e tre i seed comuni.

12.77 ± 2.05

Vanilla DQN


15.88 ± 1.93

Double DQN


+3.12

Δ paired medio

std tra delta: 1.68



Confronto paired seed-by-seed al checkpoint finale




Andamento Double DQN multi-seed

Interpretazione corretta


Con n=3 non è una prova statistica forte. È però un segnale coerente nel campione osservato.

Analisi delle ablation


quale modifica migliora il training senza introdurre instabilità?



ϵ -greedy: esponenziale più consistente



Rally: moderato stabile, aggressivo instabile




PBRS: $\kappa=0.50$ recupera nel finale

Sintesi finale a 1.8M step: migliori configurazioni per famiglia


Vanilla DQN		12.77
Double DQN		15.88
ϵ exp		14.88
Rally mod.		15.18
PBRS $\kappa=0.50$		16.42
Contact $c=0.10$		14.57

miglior finale
PBRS 0.50

Failure case: un bonus troppo forte può distorcere il training



Contact reward: $c=0.50$ molto instabile



Heatmap policy greedy: proiezione parziale della policy



Detector geometrico: visualizzazione, non training

copertura detector

$\approx 62\%$

il 38% degli stati non entra nelle heatmap

Cosa osserviamo?

- Bonus aggressivi $\rightarrow$ traiettorie degenerative.
- Contact detector sparso: pochi eventi pesano molto.
- Heatmap post-hoc; PBRS con detector parziale riduce la fedeltà teorica del potenziale.

Conclusioni — il segnale ausiliario aiuta solo se resta allineato al task

Messaggio principale

DQN impara Pong entro 1.8M step, ma target TD, esplorazione e reward shaping cambiano sensibilmente l'apprendimento.

Takeaway 1

Double DQN migliora il confronto paired finale (+3.12), ma con $n=3$ va letto come evidenza descrittiva.

Takeaway 2

PBRS $\kappa=0.50$ ottiene il miglior finale, mentre rally/contact aggressivi mostrano instabilità forte.

Takeaway 3

Le diagnostiche qualitative aiutano a spiegare i numeri, ma vanno separate dal confronto primario.

Limiti del lavoro

pochi seed · detector geometrici parziali · contatto raro · budget 1.8Mstep

Prossimi passi

più seed · training più lunghi · altri Atari · detector/stati più robusti · shaping più sistematico

**GRAZIE PER
L'ATTENZIONE**